



ArXiv-NewsBrief v4.2 프로젝트

발표자료

일반인도 이해할 수 있는 **AI** 논문 요약 시스템



목차

1. End-to-End 파이프라인
2. 데이터셋 구축
3. 베이스 모델 선택
4. 모델 학습
5. 성능 평가
6. 추가 구현사항
7. 결론

1. End-to-End 파이프라인

배경지식

arXiv는 전 세계 연구자들이 **논문 초안(preprint)**을 공개하는 오픈 저장소입니다. AI·컴퓨터과학 분야에서 가장 빠른 최신 연구 소스로 쓰입니다.

무엇이 들어 있나?

- 제목, 초록, 저자, 제출일
- 카테고리(예: cs.AI, cs.CL, cs.LG, stat.ML)
- PDF/원문 링크
- 버전 이력(v1, v2...)

핵심은 **초록(Abstract)**입니다. 요약·뉴스 브리핑 학습/추론에 가장 적합합니다.

Qwen2.5-1.5B-Instruct는 알리바바(Qwen) 계열의 소형 언어 모델로, 약 15억(1.5B) 파라미터를 가진 지시(Instruct) 최적화 모델입니다. 질문에 답하고, 요약·번역·지시 수행을 짧고 정확하게 하도록 설계되었습니다.

프로젝트 개요

항목	내용
목표	ArXiv 논문 초록을 일반인도 이해 가능한 뉴스 브리핑 스타일로 1-2문장 요약
데이터	1,845개 고품질 학습 데이터 (Teacher LLM 생성)
모델	Qwen2.5-1.5B-Instruct (LoRA Fine-tuning)
결과	v4.2 최종 성능 86/100 (B+ 등급)
비용	\$0 (Gemini 무료 + Colab T4 무료)

비교 전략

Baseline (학습 전):

- Base 모델 (Qwen2.5-1.5B-Instruct)
- 기본 instruction만
- Teacher 지식 없음
- 목적: "사전학습 모델의 기본 성능?"

Fine-tuned (학습 후):

- Teacher LLM (27B)로 생성된 1,845개 데이터
- QLoRA fine-tuning
- Teacher의 요약 스타일 학습
- 목적: "27B → 1.5B 지식 전이 가능?"

핵심 질문: "큰 모델의 지식을 작은 모델에 효과적으로 전이할 수 있는가?"

결과:

-  ROUGE-2: +21.9%
-  Teacher-Student 전략 검증 성공

2. 데이터셋 구축

왜 이 데이터셋을 구축했는가?

문제 인식: 기존 데이터셋의 한계

시도 1: **CNN/DailyMail** 뉴스 요약 데이터셋

기대: 뉴스 스타일 학습 가능

실험 결과:

- 문제점:
- 이미 대중 친화적인 뉴스 → 뉴스
- 우리 목표: 학술 논문 → 뉴스 변환
- 도메인 불일치
- 성능: Fine-tuning 후 ROUGE-2: 0.18, 개선폭 +5%만
- 결론: ❌ 학습 효과 미미
- 교훈: "도메인이 달라도 너무 다르면 안 된다"

시도 2: SciBERT 학술 요약 데이터

SciBERT는 과학 논문(생물의학·컴퓨터과학 등) 텍스트로 사전학습된 BERT 기반 언어모델입니다. 일반 BERT보다 전문 용어 이해에 강해 논문 분류, 개체명 인식, 관계 추출 같은 과학 NLP 작업에서 성능이 우수한 편입니다.

기대: 논문 도메인에서 학습

실험 결과:

- 문제점:
- 출력이 너무 짧음 (1문장 요약)
- 여전히 학술적 스타일
- "뉴스 브리핑" 느낌 전혀 없음
- 출력 예시: "We propose a novel method..." → 여전히 학술 논문체
- 결론: ❌ 스타일 변환 실패
- 교훈: "학술 → 학술은 쉽지만, 학술 → 대중은 어렵다"

시도 3: GPT-4 API로 직접 생성

기대: 최고 품질의 학습 데이터

실험 결과:

- 비용 계산:
- GPT-4: \$0.03/1K input tokens
- 논문 초록 평균: ~300 tokens
- 1,000개 생성: 300K tokens
- 총 비용: \$108 😱
- 추가 문제:
- 무료 티어 셋팅 어려움
- Temperature 조절 어려움
- 출력 일관성 낮음
- API 속도 제한
- 결론: ❌ 무료티어 서로다른환경 디버그 문제 및 1k 늘어날수록 예산 초과 (학생 프로젝트)
- 교훈: "돈으로 해결할 수 있지만, 우리는 시간과 돈이 없다"

최종 결론: 💡 직접 구축하되 빠르게 구현가능 하고 무료로! → Teacher-Student 아키텍처

해결책: **Teacher-Student** 아키텍처

Teacher-Student는 성능이 좋은 대형 모델(Teacher)의 지식을 더 작은 모델(Student)에 전달하는 학습 방식입니다.

왜 **Teacher LLM**이 필요한가?

핵심 아이디어: "큰 모델(Teacher)로 데이터 생성 → 작은 모델(Student) 학습"

장점:

1. 생성 비용: 1회만 (추론)
2. 학습 데이터: 영구 재사용
3. Student 모델: 빠른 추론
4. 총 비용: \$0 (무료 Teacher 사용)

왜 **Gemini-3-27b-it**인가?

Teacher 후보 비교 실험

대안 1: **GPT-4o-mini (OpenAI)**

스펙:

- 출시: 2024년 7월
- 품질: 우수 (MMLU 82%)
- 컨텍스트: 128K tokens

문제:

- 비용: \$0.15/1M input tokens, \$0.60/1M output
- 1,845개 생성 비용 계산:
- 논문 초록 평균: 300 tokens input
- 요약 출력 평균: 50 tokens
- Input: $1,845 \times 300 = 553,500$ tokens
- Output: $1,845 \times 50 = 92,250$ tokens
- Input 비용: \$0.08
- Output 비용: \$0.06
- 총 비용: \$0.14 (저렴함!)

실험 (100개 샘플):

- 평균 단어: 42.5
- 스타일: 뉴스 친화적 (개선됨)
- 일반인 이해도: 7.5/10
- 비용: \$0.00 (100개 기준) 그러나 셋팅 어려움

결정: ⚠️ 비용은 괜찮지만...

- API 키 필요 (설정 장벽)
- 속도 제한 존재
- 일관성: Gemini보다 낮음
- 무료 Gemini가 더 나음

대안 2: Claude-3 Sonnet (Anthropic)

스펙:

- 품질: 우수
- 추론 능력: 뛰어남

문제:

- 비용: \$0.015/1K tokens (GPT-4 절반)
- 1,000개 생성: \$54 (여전히 비쌌)
- API 접근: 제한적 (대기 명단)

결정: ❌ 비용 + 접근성

대안 3: Llama-3-70B (Meta)

스펙:

- 파라미터: 70B
- 라이선스: 오픈소스

문제:

- 로컬 실행: 불가능
- 메모리: 140GB (4-bit도 35GB)
- Colab: T4 15GB로 불가
- Together AI: 유료 (\$0.9/1M tokens)

결정: ❌ 인프라 제약

대안 4: Gemini-3-27b-it (Google) ✅

스펙:

- 파라미터: 27B
- 품질: 우수 (27B급 최상위)
- API: Google AI Studio

장점:

- 비용: \$0 (무료!) 🥰
- 속도: 빠름 (10초/샘플)
- 안정성: 높음
- 일반인 친화: 뛰어남

실험 (100개 샘플):

- 평균 단어: 41.3 ✓
- 스타일: 뉴스 브리핑 ✓
- 일반인 이해도: 8.2/10 ✓✓
- 비용: \$0 ✓✓✓
- 일관성: 높음 (std 6.7)

결정: ✓✓✓ 채택!

비교 실험 결과 (100 샘플):

Teacher	품질	이해도	1,845개 비용	선택
GPT-4o-mini	8/10	7.5/10	\$0.14	⚠
Claude-3	9/10	7.0/10	\$27	✗
Llama-70B	8/10	6.0/10	\$27	✗
Gemini-27B	8.5/10	8.2/10	\$0	✓

결론: 💰 **Gemini** = 비슷한 품질 × \$0 비용 = 무한대 가성비

GPT-4o-mini는 \$0.14로 저렴하지만, Gemini \$0가 압도적



데이터 수집 방법

원천 데이터

- 소스: HuggingFace ccdv/arxiv-summarization
- 규모: 215,000+ 논문
- 사용 범위: 인덱스 2000-3999 (2,000개 시도)
- 실제 생성: 1,845개 (성공률 92.3%)
- 분야 분포:
 - Physics: 40%
 - Computer Science: 30%
 - Mathematics: 20%
 - Others: 10%

Teacher LLM 최종 선택

기준	점수	검증 방법
고품질 출력	★★★★★	100샘플 실험: 평균 8.5/10
Instruction Following	★★★★★	프롬프트 준수율 98%
일반인 이해도	★★★★★	사람 평가: 8.2/10
비용 효율성	★★★★★	\$0 vs Claude \$20
일관성	★★★★★	표준편차 6.7 (낮음)

데이터 통계

구분	개수	비율	비고
총 생성 시도	2,000+	100%	초기 수집
성공 샘플	1,845	92.3%	품질 검증 통과
학습 데이터	1,660	90%	Training set
검증 데이터	185	10%	Validation set
실패 샘플	155	7.7%	환각, 길이 초과 등

데이터 형태

학습 데이터 예시 (**Chat Template** 적용)

```
<|im_start|>system
Summarize the following text in simple, clear English that anyone
can understand. Make it as for the each script not for reading.
Use no more than two complete sentences. Do not include my prompt
message in result. Make sure to keep in professional tone.
<|im_end|>

<|im_start|>user
Development of exponentially scaling methods has seen great progress
in tackling larger systems than previously thought possible. One such
technique, full configuration interaction quantum monte carlo, has
been demonstrated to give excellent agreement with experiments...
<|im_end|>

<|im_start|>assistant
Scientists developed a new AI system that better understands human
language by combining different learning techniques. The system
performed better than previous methods on major language tests.
<|im_end|>
```

출력 특징:

- 1-2문장 (평균 1.8문장)
- 30-45단어 (평균 41.3단어)
- 뉴스 브리핑 스타일
- 일반인 이해 가능한 표현

데이터 품질 관리

좋은 품질의 기준

형식 기준:

- 문장 수: 1-2문장
- 단어 수: 30-45단어
- 특수문자: 없음
- 프롬프트 누출: 없음

내용 기준:

- 핵심 기여도 포함: 논문의 주요 발견
- 정확성: 초록 내용과 일치
- 명료성: 일반인 이해 가능
- TTS 적합성: 자연스러운 구어체

품질 통계 (1,845개):

-  평균 단어 수: 41.3 (목표 범위 내)

-  표준편차: 6.7 (낮은 변동성)
-  2문장 비율: 67%
-  환각 발생률: 2.1% (매우 낮음)
-  전문용어 밀도: 12.3% (적절)
-  성공률: 92.3%

3. 베이스 모델 선택

들어가기 전 이해를 위한 용어집

ROUGE-2: 참조 모델과 생성 모델 사이 연속된 단어 2개(bigram)의 겹치는 정도를 표현하는 문서 요약 모델 평가지표.

MMLU: 해당 모델이 얼마나 광범위하고 다양한 주제를 이해하는지 측정하는 종합적 평가. 0부터 100 사이의 수치를 점수로 하여 해당 모델이 어느 정도 수준임을 가늠하게 함.

4-Bit 양자화: 기존 파라미터의 크기 (32Bit)를 추가 모델을 이용해 4Bit로 줄여 모델과 코드를 경량화하는 기법.

FP16/FP32: 부동 소수점 표현 기법. 숫자가 작을수록 적은 비트를 사용해 숫자를 표현함. 숫자가 작을수록 처리 속도가 빨라지고 가용하는 메모리가 적지만, 표현의 정밀도가 낮아지며, 표현할 수 있는 수의 크기가 작아짐.

BF16: FP16과 비슷한 속도와 점유율을 유지하면서 BF32의 표현 가능한 수 크기를 지닌 신규 표현 기법. 그에 대한 대가로 정밀도를 일부 희생함.

Gradient Accumulation: Batch를 쪼개어 Gradient를 생성하고, N번의 단계동안 Global Gradient에 누적시킨 후 한번에 업데이트 하는 방식. 훈련 시간이 길어지지만, 메모리 사용량을 극적으로 줄일 수 있음.

(계속 다음 섹션...)

왜 Qwen2.5-1.5B-Instruct인가?

Phase 1: 큰 모델 시도 (실패의 경험)

시도 1: Llama-3.1-8B

기대: 높은 성능 (MMLU 69.4)

실험 과정:

1. 모델 로드 시도

- Colab T4: 15GB VRAM
- FP16 8B 모델: 16GB 필요
- 결과: ❌ OOM (Out of Memory)

1. 4-bit 양자화 시도
2. 모델 크기: 4GB로 감소
3. 학습 메모리: +10GB (gradients, optimizer)
4. 총 필요: 14GB
5. 결과: ⚠️ 간신히 작동하지만...
6. 학습 시도 (Batch=1, GA=8)
7. Epoch 1: 3시간
8. 전체 5 epoch: 15시간 예상
9. Colab 세션: 최대 12시간
10. 결과: ❌ 세션 끊김, 체크포인트 날아감 😱

결론: ❌ 포기

교훈: "크기가 클수록 좋은 게 아니다 - 환경이 중요하다"

시도 2: **Phi-3-mini (3.8B)**

기대: 중간 크기로 타협

실험 과정:

1. 모델 로드
- 4-bit: 2GB ✅
- 학습 가능: ✅

1. 학습 속도 측정
2. Epoch 1: 1.5시간
3. 전체 5 epoch: 7.5시간 예상
4. Colab 세션: 가능하지만 뽁뽁
5. 요약 품질 테스트 (10 샘플)
6. ROUGE-2: 0.19
7. 문제: 문장이 너무 길어짐 (60+ 단어), 기술적 표현 과다, "간결함" 부족

결론: ⚠️ 가능하지만 비효율적

교훈: "중간은 어정쩡하다 - 차라리 작고 빠른 게 낫다"

Phase 2: 작은 모델 비교 실험 (성공으로 가는 길)

후보 모델 벤치마킹 (실제 실험)

데이터: 100개 validation samples

작업: 논문 초록 → 2문장 요약

평가: ROUGE-2, 학습 시간, 메모리

후보 1: Llama-3.2-1B

model = "Llama-3.2-1B" # Base 모델만 존재

실험 결과:

- MMLU: 49.3
- ROUGE-2: 0.15 (낮음)

문제점:

1. Instruct 버전 없음 (Base만) → 프롬프트 따라가기 어려움
2. Chat Template 불완전 → 출력 형식 불안정
3. 요약 품질 낮음 (실제 출력): "The research investigates computational methods for molecular systems, focusing on configuration interaction techniques and their applications to chemical problems..." → 55단어, 여전히 학술적 ❌

학습 시간: 14분 (빠름 ✅)

메모리: 6GB (안정 ✅)

결론: ⚠️ 속도는 좋지만 품질 부족

후보 2: Gemma-2-2B

model = "Gemma-2-2B-Instruct" # Google

실험 결과:

- MMLU: 52.2
- ROUGE-2: 0.18 (보통)

실제 출력: "This study develops new computational approaches for solving complex molecular problems using advanced sampling methods."

- 15단어, 너무 짧음 ⚠️
- 핵심 내용 누락

장점:

- Google 모델 (신뢰성)
- Instruct 잘 됨

단점:

- 요약 태스크: Qwen보다 약함

- 너무 짧게 요약하는 경향
- 정보 손실 많음

학습 시간: 18분

메모리: 7GB

결론: ⚠️ Qwen보다 못함

후보 3: Qwen2.5-1.5B-Instruct ✅

model = "Qwen2.5-1.5B-Instruct" # Alibaba

실험 결과:

- MMLU: 60.9 (1.5B급 최고!)
- ROUGE-2: 0.22 (+47% vs Llama)

실제 출력: "Scientists developed faster algorithms called Full Configuration Interaction Quantum Monte Carlo to solve complex molecular problems that were too hard before. This new approach handles much larger chemical systems than previous methods."

- 35단어, 2문장 ✅
- 핵심 전달 + 일반인 이해 가능 ✅

장점:

1. Pre-training에 요약 데이터 포함 → 요약 태스크에 강함
2. 18T tokens 학습 → 풍부한 언어 이해
3. 10M+ instruction pairs → 프롬프트 잘 따름
4. Chat Template 완벽 → 안정적 출력

학습 시간: 16분 (적절 ✅)

메모리: 8GB (안정 ✅)

일관성: 표준편차 6.7 (낮음 ✅)

결론: ✅✅✅ 최종 선택!

교훈: "크기보다 품질, 품질보다 적합성"

정량적 비교표:

모델	MMLU	ROUGE-2	학습시간	메모리	요약 품질	선택
Llama-3.2-1B	49.3	0.15	14분	6GB	⚠️ 낮음	❌
Gemma-2-2B	52.2	0.18	18분	7GB	⚠️ 짧음	❌
Qwen2.5-1.5B	60.9	0.22	16분	8GB	✅ 최고	✅

최종 선택: **Qwen2.5-1.5B-Instruct**

모델 정보:

- 모델명: Qwen2.5-1.5B-Instruct
- 타입: Instruction-tuned
- 파라미터: 1.5 Billion
- 제작사: Alibaba Cloud
- 라이선스: Apache 2.0 (상업적 사용 가능)

선택 이유 (실험 기반)

1. 태스크 적합성 (실증됨)

Pre-training 데이터:

- 데이터: 18T tokens
- 품질: High-quality multilingual corpus
- 특징:
 -  Wikipedia: 백과사전 스타일
 -  News articles: 뉴스 브리핑
 -  ArXiv papers: 학술 논문 (중요!)
 -  Conversation: 대화체

→ 우리 태스크(논문→뉴스)와 정확히 일치! 

Instruction Tuning:

- 데이터: 10M+ instruction pairs
- 태스크:
 -  Summarization (요약)
 -  Q&A (질의응답)
 -  Generation (생성)
- 품질: Human feedback (RLHF)

→ Summarization 태스크 특화! 

2. 운영 제약 충족 (완벽)

Google Colab T4 GPU 환경:

항목	요구사항	Qwen2.5-1.5B	검증 방법	상태
VRAM (모델)	< 10GB	1.5GB (4-bit)	실제 측정	✓
VRAM (학습)	< 12GB	8GB (peak)	학습 중 모니터링	✓
학습 시간	< 6시간	16.6분	5 epochs 완료	✓
추론 속도	< 5초	1.2초/샘플	100샘플 평균	✓
비용	무료	T4 무료	Colab Free tier	✓

메모리 프로파일 (실측):

Base Model (FP16):	2.8GB
4-bit Quantized:	0.7GB ← 사용
+ LoRA adapters:	0.1GB
+ Gradient buffers:	1.2GB
+ Optimizer states:	1.5GB
+ Batch data:	4.5GB
Total Peak:	8.0GB
T4 Available:	15.0GB
Margin:	7.0GB (47%) ✓ 안정적!

3. 성능 대비 효율성 (최고)

성능/파라미터 비율 계산:

모델	MMLU	GSM8K	파라미터	효율성 (MMLU/B)
Llama-3.2-1B	49.3	51.7	1B	0.493
Qwen2.5-1.5B	60.9	70.3	1.5B	0.406 ★
Gemma-2-2B	55.0	65.0	2B	0.275
Phi-3-mini	69.0	82.5	3.8B	0.182
Llama-3.1-8B	69.4	84.5	8B	0.087

Trade-off 이해:

우리의 선택:

- 크기: 1.5B (작음)
- 성능: MMLU 60.9 (1.5B급 최고)
- 속도: 1.2초/샘플 (빠름)
- 비용: \$0 (무료)

포기한 것:

- 8B 모델의 더 높은 성능 (MMLU 69+)
- 하지만: 요약 태스크엔 충분함!
- 실험 결과: ROUGE-2 0.22로 목표 달성

얻은 것:

- 빠른 실험 반복 (16분/학습)
- 안정적 학습 (OOM 없음)
- 즉시 배포 가능 (CPU도 3초)
- 무제한 무료 사용

결론: "작지만 강하다" 

4. 모델 학습



왜 QLoRA인가? (시행착오의 기록)

학습 방법 선택의 여정

시도 1: Full Fine-tuning (참담한 실패)

방법: 전체 1.5B 파라미터 학습

기대: 최고의 성능

실험 1차:

- 모델 로드 (FP16)
- 모델: 3.0GB
- Optimizer (AdamW): 6.0GB
- Gradients: 3.0GB
- Activations: 5.0GB
- Total: 17.0GB
- Colab T4: 15GB
- 결과:  OOM at model load

실험 2차 (FP16 Mixed Precision):

- 모델: 3.0GB
- Optimizer: 3.0GB (half)
- Gradients: 1.5GB (half)
- Activations: 4.0GB
- Total: 11.5GB
- 결과:  로딩 성공!

학습 시작:

- Step 1: 메모리 12.5GB
- Step 2: 13.8GB
- Step 3: 14.9GB
- Step 4: 🌟 OOM!

원인: Activation 누적

결과: ❌ 학습 불가

교훈: "전체 학습은 큰 GPU 필요하다"

시도 2: LoRA (부분 성공)

방법: Low-Rank Adaptation (FP16)

기대: 메모리 대폭 절감

실험 과정:

- 설정:
- Base model: FP16 (freeze)
- LoRA: $r=16$, $\alpha=32$
- Trainable: 10M (0.67%)

메모리 프로파일:

- 모델 (FP16): 3.0GB
- LoRA adapters: 0.2GB
- Optimizer: 3.0GB (adapters only)
- Gradients: 2.0GB
- Activations: 4.0GB
- Total: 12.2GB

Colab T4: 15GB

여유: 2.8GB (19%)

결과: ⚠️ 작동하지만 불안정

문제점:

1. Colab 세션 가끔 끊김 → 메모리 여유 부족 → Background cleanup 실패
2. Batch size 1만 가능 → Gradient accumulation 필수 → 학습 속도 느림
3. 학습 중 메모리 스파이크 → 13-14GB까지 치솟음 → 위험!

교훈: "작동은 하지만 안심할 수 없다"

시도 3: QLoRA (완벽한 해결!) ✅

방법: 4-bit Quantization + LoRA

기대: 메모리 75% 절감

실험 과정:

- 설정:
- Base model: 4-bit NF4 (freeze)
- LoRA: r=16, alpha=32
- Trainable: 10M (0.67%)

메모리 프로파일:

- 모델 (4-bit): 0.7GB ↓ 76% 절감!
- LoRA adapters: 0.1GB
- Optimizer: 1.5GB ↓ 50% 절감
- Gradients: 1.2GB ↓ 40% 절감
- Activations: 4.5GB
- Total: 8.0GB

Colab T4: 15GB

여유: 7.0GB (47%) ✓✓✓

결과: ✓ 완벽하게 안정적!

장점:

1. 메모리 여유 넉넉 → 세션 안정적 → Background cleanup 여유
2. Batch size 1 + GA 4 → 효율적 학습 → 속도 괜찮음
3. 메모리 스파이크 여유 → Peak 8.5GB (safe!) → 절대 OOM 없음

교훈: "양자화는 마법이다!" ✨

⚙️ Configuration 구성

양자화 설정

```
BitsAndBytesConfig(
    load_in_4bit=True,
    bnb_4bit_quant_type="nf4",
    bnb_4bit_compute_dtype=torch.float16,
    bnb_4bit_use_double_quant=True
)
```

효과:

- FP16: 2.8GB → 4-bit NF4: 0.7GB (75% 절감)
- 정확도 손실: < 1%

LoRA 설정

```
LoraConfig(  
    r=16,  
    lora_alpha=32,  
    target_modules=["q_proj", "k_proj", "v_proj", "o_proj"],  
    lora_dropout=0.1,  
    bias="none",  
    task_type="CAUSAL_LM"  
)
```

파라미터 분석:

전체 파라미터:	1,543,319,552 (1.5B)
학습 파라미터:	10,354,688 (10M)
학습 비율:	0.67%
메모리 절감:	~99.3%



하이퍼파라미터 선택 (실험 기반)

Epochs: 왜 5인가?

실험: **Epochs**별 성능 비교

3 Epochs:

- Train Loss: 1.45
- Val Loss: 1.65
- ROUGE-2: 0.19
- 문제: Val loss 여전히 높음, 수렴 부족
- 결론: ⚠ Under-fitting

5 Epochs: ✅

- Train Loss: 1.18
- Val Loss: 1.09
- ROUGE-2: 0.22
- 관찰: Val loss 최저점 도달, Train/Val gap 작음 (0.09)
- 결론: ✅ 최적점!

7 Epochs:

- Train Loss: 0.95
- Val Loss: 1.15
- ROUGE-2: 0.21
- 문제: Val loss 상승! (1.09 → 1.15), Train/Val gap 커짐 (0.20)
- 결론: ❌ Over-fitting

결정: 5 Epochs

이유: Val loss 최저점, 과적합 없음

Learning Rate: 왜 2e-4인가?

실험: LR별 학습 곡선 비교

1e-4 (너무 낮음):

- Epoch 1 loss: 2.15
- Epoch 5 loss: 1.25
- 수렴 속도: 느림
- 문제: 5 epoch로 충분히 학습 안 됨
- 결론: ⚠ 비효율적

2e-4 (최적): ✅

- Epoch 1 loss: 1.87
- Epoch 5 loss: 1.09
- 수렴 속도: 적절
- 관찰: 매 epoch 안정적 개선, 진동 없음
- 결론: ✅ 완벽!

5e-4 (너무 높음):

- Epoch 1 loss: 1.65
- Epoch 3 loss: 1.18
- Epoch 5 loss: 1.32 (상승!)
- 문제: Loss 진동 심함, Epoch 4-5에서 불안정
- 결론: ❌ 불안정

결정: 2e-4

이유: LoRA 권장값, 안정적 수렴, 적절한 속도

Temperature: 왜 0.4인가? (핵심!)

v4.0 → v4.2 진화 과정

v4.0: Temperature 0.7

- 문제 발견 (100 samples 테스트):
- 2문장 준수: 33% 😱
- 특수문자 발생: 67%
- 출력 변동성: 표준편차 18.5
- 형식 점수: 42/50
- 예시 출력: "Scientists developed... <|im_end|>", "### Summary ### This research..."
- 결론: ❌ 불안정, 배포 불가

v4.1: Temperature 0.5

- 개선 테스트 (100 samples):
- 2문장 준수: 85% (↑)
- 특수문자: 20% (↓)
- 출력 변동성: 표준편차 8.2
- 형식 점수: 46/50
- 결론: ⚠️ 아직 부족

v4.2: Temperature 0.4 ✅

- 최종 테스트 (100 samples):
- 2문장 준수: 94% ✅ (+61%p vs v4.0)
- 특수문자: 0% ✅✅✅ (완벽!)
- 출력 변동성: 표준편차 6.7
- 형식 점수: 48/50
- Trade-off: 창의성 약간 감소, TTS 자연스러움 2.5/5 (약간 하락), 하지만: 형식 안정성이 우선!
- 결론: ✅ 배포 가능!

결정: 0.4

이유: 형식 안정성 최우선, 특수문자 100% 제거

📋 최종 하이퍼파라미터 표

파라미터	값	선택 이유
Epochs	5	Val loss 최저점 (1.09)
Learning Rate	2e-4	안정적 수렴
Temperature	0.4	특수문자 0% (v4.2)
Batch Size	1	메모리 8GB (안정)
Gradient Accumulation	4	Effective BS = 4
Warmup Steps	10	전체 520 steps의 ~2%
Max Length	512	초록(300) + 요약(50) 충분
FP16	True	속도 2배, 메모리 50%
Scheduler	Cosine	안정적 수렴

📈 학습 곡선

Loss 변화:

Epoch	Train Loss	Eval Loss	Perplexity
0 (초기)	-	2.847	17.23
1	2.451	1.873	6.51
2	1.872	1.524	4.59
3	1.523	1.312	3.71
4	1.314	1.183	3.26
5 (최종)	1.184	1.092	2.98

분석:

- ☒ 안정적 수렴 (Smooth curve)
- ☒ Overfitting 없음 (Eval loss 지속 감소)
- ☒ 5 에포크 적절 (더 학습 시 개선 미미)

5. 성능 평가

배경지식

LLM-as-a-Judge는 생성된 데이터셋과 실제 데이터셋을 비교하여 평가하고, 이를 통해 모델의 응답 품질을 지속적으로 개선하는 평가방식입니다.

LLM-as-a-judge로 Chatbot Arena를 MT-bench 방식으로 LLM 평가 결과논문에 따르면 MT-bench의 전문가 투표와 Chatbot Arena에서 수집된 클라우드 투표 결과를 비교했을 때 GPT-4 judge와 사람의 선호의 일치도가 80% 이상으로, 사람간의 평가와 유사한 성능을 보여 관심을 갖게 되었습니다.



평가 방법론

LLM-as-a-Judge 평가 시스템

핵심 설계 원칙:

원칙 1: Separation of Concerns (관심사 분리)

- 형식 평가 (50점): Code-based (자동화)
- 내용 평가 (50점): LLM-based (전문성 필요)

원칙 2: Absolute Evaluation (절대 평가)

- 각 샘플 독립 평가
- 이전 버전과 무관
- 언제든지 재평가 가능

원칙 3: 100점 체계 (해상도 10배 향상)

- 10점: 5단계 유효 해상도
- 100점: 55단계 유효 해상도
- 통계적 검증력 확보

형식 평가 (50점) - **Code-based**

항목	배점	측정 방법	통과 기준
문장 수	20점	<code>len(re.split(r'[.!?]+', text))</code>	정확히 2문장
단어 수	15점	<code>len(text.split())</code>	30-45단어
특수문자	10점	Regex 패턴 매칭	<code>< im_start ></code> , <code>###</code> 등 0개
프롬프트 누출	5점	키워드 검색	"summarize", "system" 등 0개

장점:

-  100% 재현 가능
-  즉시 실행 (<1초)
-  비용 \$0

내용 평가 (50점) - **LLM-based**

항목	배점	평가 대상	핵심 질문
핵심 기여도	20점	주요 발견/기여	"논문의 핵심 결과가 포함되었는가?"
정확성	15점	사실관계	"초록 내용과 일치하는가?"
명료성	10점	이해 난이도	"일반인이 이해 가능한가?"
TTS 자연스러움	5점	구어체 적합성	"읽었을 때 자연스러운가?"

평가 모델: GPT-4 / Claude Sonnet 4



정량적 평가 결과

ROUGE Scores

메트릭	Base 모델	Fine-tuned (v4.2)	개선도
ROUGE-1 (F1)	0.420	0.479	+14.0% 
ROUGE-2 (F1)	0.183	0.223	+21.9% 
ROUGE-L (F1)	0.384	0.445	+15.9% 

BERTScore

메트릭	Base 모델	Fine-tuned (v4.2)	개선도
Precision	0.831	0.867	+4.3%
Recall	0.808	0.849	+5.1%
F1	0.819	0.858	+4.8% 

v4.2 대규모 검증 (100 Samples)

v4.2 평가 결과 (100 samples)

평균 점수: 86.3/100 (B+ 등급)

형식 점수: 48.2/50 (96.4%)

문장 수: 18.8/20 (94% 2문장 준수)

단어 수: 13.9/15 (평균 52.4단어)

특수문자: 10.0/10 (100% 제거 )

프롬프트 누출: 5.0/5 (100% 방지 )

내용 점수: 38.1/50 (76.2%)

핵심 기여도: 15.8/20 (79%)

정확성: 12.7/15 (85%)

명료성: 7.1/10 (71%)

TTS 자연스러움: 2.5/5 (50%) 

등급 분포:

A (90-100점): 23% (23/100)

B (80-89점): 45% (45/100) ← 최빈값

C (70-79점): 28% (28/100)

D (60-69점): 4% (4/100)

F (<60점): 0% (0/100)

표준편차: 6.7점

6. 추가 구현사항

웹 챗봇 진화 과정: v4.2 → v4.4.3

17 버전 타임라인

버전	날짜	주요 개선사항	핵심 기능
v4.2	2026-01-12	기본 GGUF 챗봇	텍스트 요약, 뉴스 브리프
v4.4	2026-01-13	NPR/BBC 스타일	General Public 모드 (T=0.6)
v4.4.1	2026-01-13	음성 기능 강화	실시간 녹음, 스마트 날짜
v4.4.2	2026-01-14	듀얼 스타일	General vs Researcher
v4.4.3	2026-01-14	분야 확장	12개 연구 카테고리

총 개발 기간: 5일

업데이트 횟수: 6회

주요 개선 방향: 안정성 → 자연스러움 → 사용자 선택권 → 분야 확장

v4.4.2: 듀얼 스타일 시스템

스타일 비교표:

Feature	General Public (v4.4)	Researcher (v4.2)
대상 청중	일반 청취자	연구자/전문가
Temperature	0.6 (높음)	0.4 (낮음)
Jargon 처리	❌ Zero (대체 필수)	✅ Allowed (정확성)
Real Examples	✅ Required	△ Optional
Tone	NPR/BBC News	Professional/Academic
TTS 자연스러움	4.5/5 ★ (+80%)	2.5/5
Technical Accuracy	High	Very High ★
단어 수	38-45	28-35 (간결)
전문용어	0-1개	4-6개

v4.4.3: 카테고리 선택 시스템

12개 연구 분야 지원:

1.  AI & Machine Learning
2.  Computer Science (All)
3.  Physics (All)
4.  Mathematics
5.  Biology & Life Sciences
6.  Chemistry
7.  Astrophysics & Cosmology
8.  Quantum Physics
9.  Economics & Finance
10.  Statistics
11.  Medicine & Health
12.  Engineering & Robotics

최종 기능 요약 (v4.4.3)

- ✓ 듀얼 스타일 시스템 (v4.4.2)
 - ✓ 12개 연구 분야 (v4.4.3)
 - ✓ 자동 뉴스 브리프
 - ✓ 음성 입출력 (v4.4.1-2)
 - ✓ 다국어 지원
 - ✓ GGUF 최적화
-

7. 결론 및 성과

🏆 정량적 성과 (최종)

항목	결과	검증 방법
데이터셋	1,845개 (무료)	Teacher-Student (Gemini)
학습 시간	16.6분	Colab T4, 5 epochs
vs Phi-3	27배 빠름	7.5시간 vs 16.6분
성능 (v4.2)	86/100 (B+)	LLM Judge (100 samples)
ROUGE-2	+21.9% 개선	Base vs Fine-tuned
특수문자	0% (완벽)	v4.0: 67% → v4.2: 0%
메모리	8GB (53% 절감)	QLoRA vs Full FT
챗봇 버전	v4.4.3	6차 업데이트 (5일)
지원 분야	12개	AI → 전 분야 확장
TTS 개선	+80%	v4.2: 2.5/5 → v4.4: 4.5/5
STT 개선	+40%p	v4.4.1: 60% → v4.4.2: 95%
총 비용	\$0	완전 무료 시스템 ✅

💡 핵심 교훈

1. 제약이 혁신을 낳는다

제약 1: 예산 \$0

- 결과: Gemini 무료 발견 → Teacher-Student 아키텍처 → 완전 무료 파이프라인
- 가치: ✅ 지속가능한 시스템, 무제한 확장 가능, 실제 배포 가능

제약 2: GPU 16GB (Colab T4)

- 결과: Qwen2.5-1.5B 선택 → QLoRA 4-bit → 메모리 53% 절감
- 가치: ✅ 누구나 재현 가능, 빠른 실험 (16분), 실용성 > 벤치마크

제약 3: 시간 부족 (학기 중)

- 결과: 빠른 iteration (16분) → 하루 10+ 실험 → Agile 개발
- 가치: ✅ 빠른 학습, 즉시 검증, 신속한 개선

핵심: "돈/시간/리소스가 풍부했다면 이만큼 배우지 못했을 것" → 제약 = 창의력의 원천 → 효율성 = 경쟁력

2. 실패는 학습의 시작

실패 1: CNN/DailyMail (Week 1)

- 기대: "기존 데이터셋 쓰면 편하겠지"
- 결과: ROUGE 0.15, 사용 불가
- 교훈: 도메인 특화 데이터 필수 → Teacher-Student 설계

실패 2: Llama-3-8B (Week 2)

- 기대: "큰 모델이 더 좋겠지"
- 결과: OOM, 2일 낭비
- 교훈: 제약 조건 먼저 확인 → 1.5B 모델 탐색

실패 3: v4.0 (Week 3)

- 기대: "학습 잘 됐는데?"
- 결과: 67% 특수문자, 배포 불가
- 교훈: 대규모 테스트 필수 → 3일 디버깅 → v4.2 완성

패턴: 실패 → 분석 → 가설 → 실험 → 개선

핵심: "실패 없는 성공은 없다", "각 실패에서 구체적 교훈 도출", "실패를 두려워하지 말고 분석하라"

3. 데이터가 모든 것을 말한다

감정 vs 데이터

상황 1 (v4.0):

- 감정: "잘 나온 것 같은데?"
- 데이터: 67% 특수문자, 77/100
- 결정: 데이터 신뢰 → 수정

상황 2 (Teacher 선택):

- 감정: "GPT-4가 최고 아닐까?"
- 데이터: Gemini 8.2/10, \$0
- 결정: 데이터 기반 → Gemini

상황 3 (Temperature):

- 감정: "높이면 좋아질 거야"
- 데이터: 실험 → 더 나빠짐
- 결정: 실험 검증 → 0.4 유지

원칙:

1. 모든 선택에 실험
2. 최소 50-100 samples
3. 정량 지표 필수
4. A/B 테스트

핵심: "In God we trust, all others bring data" → 직관 ❌ → 측정 ✅ → 실험으로 증명

4. Trade-off를 이해하고 존중하라

Trade-off 1: 안정성 vs 자연스러움

- v4.2 선택: Temperature 0.4, 우선순위: 안정성 (배포 급함), 결과: 0% 특수문자, TTS 2.5/5
- v4.4.2 개선: 듀얼 스타일, 사용자 선택권, 결과: 둘 다 만족 ✅
- 교훈: "완벽한 답은 없다, 상황에 맞는 선택이 있을 뿐"

Trade-off 2: 크기 vs 효율

- 선택: Qwen 1.5B (작음)
- 이유: 무료 GPU 가능, 빠른 iteration, 충분한 성능
- 결과: ✅ 27배 빠름, 누구나 재현, △ 성능 -2점 (허용)
- 교훈: "80% 성능 + 100% 속도 > 100% 성능 + 20% 속도"

5. 반복적 개선의 가치

Iteration 전략:

- v4.2 (86점, 안정화) → 사용자 피드백: TTS 부자연
- v4.4 (NPR 스타일) → 전문가 니즈 발견
- v4.4.2 (듀얼 스타일) → 분야 확장 요청
- v4.4.3 (12개 카테고리)

핵심 원칙:

1. 빠른 배포 (v4.2: 3일)
2. 피드백 수집
3. 데이터 기반 개선
4. 신속한 업데이트 (5일 6회)

효과:

- ✅ 실제 사용자 니즈 파악
- ✅ 우선순위 명확화
- ✅ 점진적 완성도 향상
- ✅ 지속적 가치 창출

교훈: "Done > Perfect", "Ship early, iterate fast", "Users tell you what to build"



최종 성과 요약

기술적 성과:

- ✅ Teacher-Student 아키텍처
- ✅ QLoRA 4-bit 최적화
- ✅ 듀얼 스타일 시스템
- ✅ 12개 연구 분야 지원

- ☒ 실시간 음성 인터페이스
- ☒ 다국어 번역

정량적 성과:

- ☒ 86/100 (B+) 성능
- ☒ ROUGE-2 +21.9%
- ☒ 학습 시간 95% 단축
- ☒ 특수문자 0%
- ☒ TTS +80% 개선
- ☒ STT +40%p 개선
- ☒ 총 비용 \$0

학습 성과:

- ☒ 실패 분석 능력
- ☒ 실험 설계 능력
- ☒ 디버깅 능력
- ☒ 프로덕션 경험
- ☒ 문서화 능력
- ☒ 오픈소스 기여



참고 자료

프로젝트 문서

- **GitHub**: <https://github.com/chopeacekr/my-news-briefing>

주요 논문

1. **LoRA**: Low-Rank Adaptation (Hu et al., 2021)
2. **QLoRA**: Efficient Finetuning (Dettmers et al., 2023)
3. **Qwen2.5**: Technical Report (Alibaba, 2024)
4. **LLM-as-a-Judge**: Evaluation Framework

© 2026 ArXiv-NewsBrief Project. MIT License.

© 2026 ArXiv-NewsBrief Project. MIT License.

GitHub: <https://github.com/chopeacekr/my-news-briefing>

Generated: 2026-01-14 | Document: ArXiv-NewsBrief v4.2 Full Report